

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
Estatísticas e suas distribuições

# Introdução às Probabilidades

tradução do Jay Davore

## índice

- 1 Distribuições de probabilidade conjunta e Amostras Aleatórias
  - Variáveis aleatórias conjuntamente distribuídas
  - Função massa de probabilidade marginal
  - Função densidade de probabilidade conjunta
  - Função densidade de probabilidade marginal
- 2 Variáveis aleatórias independentes
  - Independência
  - Função de probabilidade condicional
- 3 Valores esperados, Covariâncias e Correlação
  - Valores esperados
  - Covariância
  - Correlação

Distribuições de probabilidade conjunta e Amostras Aleatórias

Variáveis aleatórias independentes

Valores esperados, Covariâncias e Correlação

Estatísticas e suas distribuições

Variáveis aleatórias conjuntamente distribuídas

Função massa de probabilidade marginal

Função densidade de probabilidade conjunta

Função densidade de probabilidade marginal

## Funções conjuntamente distribuídas

Trabalhamos até agora com funções de probabilidade de uma única v.a. Agora, definiremos para quaisquer variáveis aleatórias  $X$  e  $Y$  a função de distribuição de probabilidade cumulativa conjunta de  $X$  e  $Y$  como

$$F(a, b) = P\{X \leq a, Y \leq b\} \quad -\infty < a, b < \infty$$

Distribuições de probabilidade conjunta e Amostras Aleatórias

Variáveis aleatórias independentes

Valores esperados, Covariâncias e Correlação

Estatísticas e suas distribuições

Variáveis aleatórias conjuntamente distribuídas

Função massa de probabilidade marginal

Função densidade de probabilidade conjunta

Função densidade de probabilidade marginal

## Funções conjuntamente distribuídas

Trabalhamos até agora com funções de probabilidade de uma única v.a. Agora, definiremos para quaisquer variáveis aleatórias  $X$  e  $Y$  a função de distribuição de probabilidade cumulativa conjunta de  $X$  e  $Y$  como

$$F(a, b) = P\{X \leq a, Y \leq b\} \quad -\infty < a, b < \infty$$

## Funções conjuntamente distribuídas

A função de distribuição de  $X$  (marginal) pode ser obtida a partir da conjunta de  $X$  e  $Y$  da seguinte forma:

$$\begin{aligned}F_X(a) &= P(X \leq a) \\&= P(X \leq a, Y < \infty) \\&= P\left(\lim_{b \rightarrow \infty} \{X \leq a, Y \leq b\}\right) \\&= F(a, \infty)\end{aligned}$$

## Marginais

$$\begin{aligned}P(X > a, Y > b) &= 1 - P(X > a, Y > b)^c \\&= 1 - P((X > a)^c \cup (Y > b)^c) \\&= 1 - P((X \leq a) \cup (Y \leq b)) \\&= 1 - [P(X \leq a) + P(Y \leq b) - P(X \leq a, Y \leq b)] \\&= 1 - F_X(a) - F_Y(b) + F(a, b)\end{aligned}$$

## Função Massa de probabilidade conjunta

Sejam  $X$  e  $Y$  duas v.a. discretas definidas no espaço amostral de um experimento. A **função massa de probabilidade conjunta**  $p(x, y)$  é definida para cada par de números  $(x, y)$  por

$$p(x, y) = P(X = x \text{ e } Y = y)$$

Seja  $A$  o conjunto que contém os valores dos pares  $(x, y)$ , então:

$$P[(X, Y) \in A] = \sum_{(x,y) \in A} \sum p(x, y)$$

## Definição

A função massa de probabilidade conjunta de  $X$  e  $Y$ , denotada por  $p_X(x)$  e  $p_Y(y)$ , são dados respectivamente por:

$$p_X(x) = \sum_y p(x, y)$$

$$p_Y(y) = \sum_x p(x, y)$$



Distribuições de probabilidade conjunta e Amostras Aleatórias

Variáveis aleatórias independentes

Valores esperados, Covariâncias e Correlação

Estatísticas e suas distribuições

Variáveis aleatórias conjuntamente distribuídas

**Função massa de probabilidade marginal**

Função densidade de probabilidade conjunta

Função densidade de probabilidade marginal

## Exemplo

Suponha que três bolas sejam sorteadas de uma urna contendo 3 bolas vermelhas, 4 bolas brancas e 5 bolas azuis. Se  $X$  e  $Y$  representam respectivamente, o número de bolas vermelhas e brancas escolhidas, então a função de probabilidade conjunta de  $X$  e  $Y$ ,  $p(i, j) = P(X = i, Y = j)$  é dada por:

## exemplo

$$p(0, 0) = \frac{\binom{5}{3}}{\binom{12}{3}} = \frac{10}{220}$$

$$p(0, 1) = \frac{\binom{4}{1} \binom{5}{2}}{\binom{12}{3}} = \frac{40}{220}$$

... = .....

$$p(1, 1) = \frac{\binom{3}{1} \binom{4}{1} \binom{5}{1}}{\binom{12}{3}} = \frac{60}{220}$$

.....

## exemplo

representação das probabilidades numa tabela de dupla entrada:

i	j				soma linha
	0	1	2	3	
0	$\frac{10}{220}$	$\frac{40}{220}$	$\frac{30}{220}$	$\frac{40}{220}$	$\frac{84}{220}$
1	$\frac{30}{220}$	$\frac{60}{220}$	$\frac{18}{220}$	0	$\frac{108}{220}$
2	$\frac{15}{220}$	$\frac{12}{220}$	0	0	$\frac{27}{220}$
3	$\frac{1}{220}$	0	0	0	$\frac{1}{220}$
Soma Coluna	$\frac{56}{220}$	$\frac{112}{220}$	$\frac{48}{220}$	$\frac{4}{220}$	

## Definição

Sejam  $X$  e  $Y$  v.a.contínuas. Então  $f(x, y)$  é uma função densidade de probabilidade conjunta para  $X$  e  $Y$  se para qualquer conjunto bi-dimensional  $A$ ,


$$P[(X, Y) \in A] = \int_A \int f(x, y) dx dy$$

Se  $A$  é um retângulo bidimensional:

$$\{(x, y) : a \leq x \leq b, c \leq y \leq d\},$$

$$P[(X, Y) \in A] = \int_a^b \int_c^d f(x, y) dy dx$$

## exemplo



$$P[(X, Y) \in A]$$

= Volúmen abaixo da superfície acima de  $A$

**Figura:** Representação de uma v.a. bidimensional

## Definição

A função densidade de probabilidade marginal de  $X$  e  $Y$ , denotada por  $f_X(x)$  e  $f_Y(y)$ , são dados respectivamente por:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \quad \text{para } -\infty < x < \infty$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx \quad \text{para } -\infty < y < \infty$$

## Exemplo

A função de densidade conjunta de  $X$  e  $Y$  é dada por:

$$f(x, y) = \begin{cases} 2e^{-x}e^{-2y} & 0 < x < \infty, 0 < y < \infty \\ 0 & \text{caso contrário} \end{cases}$$

calcule:

- ❶  $P(X > 1, Y < 1)$
- ❷  $P(X < Y)$
- ❸  $P(X < a)$

## Exemplo

Solução a):

$$\begin{aligned}P(X > 1, Y < 1) &= \int_0^1 \int_1^\infty 2e^{-x}e^{-2y} dx dy \\&= \int_0^1 2e^{-2y}(-e^{-x}|_1^\infty) dy \\&= e^{-1}(1 - e^{-2})\end{aligned}$$



## Exemplo

Solução b)

$$\begin{aligned}P(X < Y) &= \int_{(x,y): x < y} \int 2e^{-x} e^{-2y} dx dy \\&= \int_0^{\infty} \int_0^y 2e^{-x} e^{-2y} dx dy \\&= \int_0^{\infty} 2e^{-2y} (1 - e^{-y}) dy \\&= \int_0^{\infty} 2e^{-2y} dy - \int_0^{\infty} 2e^{-3y} dy \\&= 1 - \frac{2}{3} = \frac{1}{3}\end{aligned}$$

Distribuições de probabilidade conjunta e Amostras Aleatórias

Variáveis aleatórias independentes

Valores esperados, Covariâncias e Correlação

Estatísticas e suas distribuições

Variáveis aleatórias conjuntamente distribuídas

Função massa de probabilidade marginal

Função densidade de probabilidade conjunta

Função densidade de probabilidade marginal

## exemplo

Solução c)

$$\begin{aligned}P(X < a) &= \int_0^a \int_1^{\infty} 2e^{-x} e^{-2y} dy dx \\&= \int_0^a e^{-x} dx \\&= 1 - e^{-a}\end{aligned}$$

## definição

Duas variáveis  $X$  e  $Y$  são independentes se para cada par de valores  $x$  e  $y$ ,

$$p(x, y) = p_X(x) \cdot p_Y(y)$$

Quando  $X$  e  $Y$  são discretos, ou

$$f(x, y) = f_X(x) \cdot f_Y(y)$$

quando  $X$  e  $Y$  são contínuos.

Se as condições não são satisfeitas para todo  $(x, y)$ , então  $X$  e  $Y$  são dependentes.

## Exemplo

Um homem e uma mulher decidem se encontrar em certo lugar. Se cada um deles chega independentemente em um tempo uniformemente distribuído entre 12:00 e 13:00, determine a probabilidade de que o primeiro a chegar tenha que esperar mais de 10 minutos

## exemplo

Se  $X$  e  $Y$  são os tempos de chegada (após meio-dia) do homem e da mulher, então  $X$  e  $Y$  são v.a. independentes, com distribuição uniforme no intervalo  $(0, 60)$ .

Queremos calcular:

$$P(X + 10 < Y) + P(Y + 10 < X)$$

o que é igual (por simetria) a  $2P(X + 10 < Y)$

## exemplo

Se  $X$  e  $Y$  são os tempos de chegada (após meio-dia) do homem e da mulher, então  $X$  e  $Y$  são v.a. independentes, com distribuição uniforme no intervalo  $(0, 60)$ .

Queremos calcular:

$$P(X + 10 < Y) + P(Y + 10 < X)$$

o que é igual (por simetria) a  $2P(X + 10 < Y)$

## exemplo

$$\begin{aligned} 2P(X + 10 < Y) &= 2 \iint_{x+10 < y} f(x, y) dx dy \\ &= 2 \iint_{x+10 < y} f_X(x) f_Y(y) dx dy \quad \text{pela independência} \\ &= 2 \int_{10}^{60} \int_0^{y-10} \left(\frac{1}{60}\right)^2 dx dy \\ &= \frac{2}{(60)^2} \int_{10}^{60} (y - 10) dy \\ &= \frac{25}{36} \end{aligned}$$

## Mais de duas variáveis

Se  $X_1, X_2, \dots, X_n$  são todas v.a. discretas. A f.p.conjunta das v.a. é a função:

$$p(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$$

Se as variáveis são contínuas, a f.d.p. conjunta é a função tal que para qualquer dos  $n$  intervalos  $[a_1, b_1], \dots, [a_n, b_n]$

$$P(a_1 \leq X_1 \leq b_1, \dots, a_n \leq X_n \leq b_n) = \int_{a_1}^{b_1} \dots \int_{a_n}^{b_n} f(x_1, \dots, x_n) dx_n \dots dx_1$$



## Independência de mais de duas v.a.

As v.a.  $X_1, \dots, X_n$  são independentes se para cada subconjunto  $X_{i_1}, X_{i_2}, \dots, X_{i_n}$  das variáveis, a f.m.p (f.p.) conjunta ou f.d.p. conjunta do subconjunto é igual ao produto das f.m.p marginais ou f.d.p. marginais.

## Exemplo

Se a função de densidade conjunta de  $X$  e  $Y$  é

$$f(x, y) = \begin{cases} 6e^{-2x}e^{-3y} & \text{na região } 0 < x < \infty, 0 < y < \infty \\ 0 & \text{caso contrário} \end{cases}$$

verifique se as variáveis aleatórias são independentes

## Exemplo

Solução:

Se fizermos  $X$  e  $Y$  variáveis aleatórias exponenciais, teremos:

$$f(x) = \begin{cases} 2e^{-2x} & \text{na região } 0 < x < \infty \\ 0 & \text{caso contrário} \end{cases}$$

$$f(y) = \begin{cases} 3e^{-3y} & \text{na região } 0 < y < \infty \\ 0 & \text{caso contrário} \end{cases}$$

## Definição

Sejam  $X$  e  $Y$  duas v.a. contínuas com f.d.p conjunta  $f(x, y)$  e f.d.p marginal de  $X$   $f_X(x)$ . Então, para qualquer valor  $x$  de  $X$ , para o qual  $f_X(x) > 0$ , a função densidade de probabilidade condicional (f.d.p. condicional) de  $Y$  dado  $X = x$  é:

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} \quad -\infty < y < \infty$$

Se  $X$  e  $Y$  são discretos, substituindo f.d.pt's por f.m.p.t's resultarão na função massa de probabilidade condicional de  $Y$  quando  $X = x$

## Funções de uma variável aleatória

Suponha que uma v.a.  $X$  tem f.p.  $f$  (discreta) e que outra v.a.  $Y = r(X)$  é definida como função de  $X$ . Então, a f.p.  $g$  de  $Y$  pode ser derivada de  $f$  de uma forma direta como segue:

para qualquer valor possível  $y$  de  $Y$ ,

$$\begin{aligned} g(y) &= P(Y = y) = P(r(X) = y) \\ &= \sum_{x:r(x)=y} f(x) \end{aligned}$$

## Funções de uma variável aleatória

Se  $X$  tem f.d.p.  $f$  (contínua), e que uma v.a.  $Y = r(X)$  é definida. a função de distribuição acumulada  $G(y)$  de  $Y$  pode ser derivado como segue:

$$\begin{aligned} G(y) &= P(Y \leq y) = P(r(X) \leq y) \\ &= \int_{\{x: r(x) \leq y\}} f(x) dx \end{aligned}$$

## Função de uma variável aleatória

Se a v.a.  $Y$  tem uma função de distribuição contínua, sua f.d.p.  $g$  pode ser obtida da relação:

$$g(y) = \frac{dG(y)}{dy}$$

## Exemplo

Suponha que  $X$  tem uma distribuição no intervalo  $(-1, 1)$ , tal que

$$f(x) = \begin{cases} 1/2 & \text{para } -1 < x < 1 \\ 0 & \text{caso contrário} \end{cases}$$

determinar a f.d.p. da v.a.  $Y = X^2$



## Exemplo

Como  $Y = X^2$ , então  $Y$  deve pertencer ao intervalo  $0 \leq Y \leq 1$ . Assim, para qualquer valor de  $Y$  tal que  $0 < Y < 1$ , a f.de distribuição acumulada  $G(y)$  de  $Y$  é

$$\begin{aligned} G(Y) &= P(Y \leq y) = P(X^2 \leq y) \\ &= P(-y^{1/2} \leq X \leq y^{1/2}) \\ &= \int_{-y^{1/2}}^{y^{1/2}} f(x) dx = y^{1/2} \end{aligned}$$

## Exemplo

Para  $0 < y < 1$ , segue-se que a f.d.p.  $g(y)$  de  $Y$  é

$$g(y) = \frac{dG(y)}{dy} = \frac{1}{2y^{1/2}}$$

## Funções de duas ou mais variáveis aleatórias

Suponha que  $n$  v.a.  $X_1, \dots, X_n$  tem f.d.p.conjunta discreta  $f$ , e que  $m$  funções  $Y_1, \dots, Y_m$  de estas  $n$  variáveis são definidas como segue:

$$Y_1 = r_1(X_1, \dots, X_n)$$

$$Y_2 = r_2(X_1, \dots, X_n)$$

.....

$$Y_m = r_m(X_1, \dots, X_n)$$

## Funções de duas ou mais variáveis aleatórias

Para valores dados  $y_1, \dots, y_m$  das  $m$  v.a.  $Y_1, \dots, Y_m$ , seja  $A$  o conjunto de todos os pontos  $(x_1, \dots, x_n)$  tal que

$$r_1(x_1, \dots, x_n) = y_1$$

$$r_2(x_1, \dots, x_n) = y_2$$

.....

$$r_m(x_1, \dots, x_n) = y_m$$

Então a f.p.conjunta  $g$  de  $Y_1, \dots, Y_m$  é especificado no ponto  $(y_1, \dots, y_m)$  pela relação:

$$g(y_1, \dots, y_m) = \sum_{(x_1, \dots, x_n) \in A} f(x_1, \dots, x_n)$$

## Funções de duas ou mais variáveis aleatórias

Se a função de distribuição conjunta de  $X_1, \dots, X_n$  (continua) é  $f(x_1, \dots, x_n)$  e se  $Y = r(X_1, \dots, X_n)$ , então a função de distribuição acumulada  $G(y)$  de  $Y$  pode ser determinada da seguinte forma:

Para qualquer valor dado de  $y$  ( $-\infty < y < \infty$ ), seja  $A_y$  um subconjunto de  $R^n$  que contém os pontos  $(x_1, \dots, x_n)$  tal que  $r(x_1, \dots, x_n) \leq y$ , então:

$$\begin{aligned} G(y) &= P(Y \leq y) = P(r(X_1, \dots, X_n) \leq y) \\ &= \int_{A_y} \dots \int f(x_1, \dots, x_n) dx_1 \dots dx_n \end{aligned}$$

## Distribuição do máximo e o mínimo em uma amostra aleatória

Suponha que as v.a.  $X_1, \dots, X_n$  formam uma a.a. de tamanho  $n$  de uma distribuição para a qual a f.d.p. é  $f$  e a f.de distribuição acumulada é  $F$ . Considere as v.a.  $Y_n$  e  $Y_1$  definidas como

$$Y_n = \max\{X_1, \dots, X_n\}$$

e

$$Y_1 = \min\{X_1, \dots, X_n\}$$

determine as f.d.p. de cada uma delas.

## Distribuição do máximo e o mínimo em uma amostra aleatória

Para o caso  $Y_n$ ,

$$\begin{aligned} G_n(y) &= P(Y_n \leq y) = P(X_1 \leq y, \dots, X_n \leq y) \\ &= P(X_1 \leq y) \dots P(X_n \leq y) \\ &= F(y) \dots F(y) = [F(y)]^n \end{aligned}$$

a f.d.p de  $Y_n$  pode ser determinado derivando:

$$g_n(y) = n [F(y)]^{n-1} f(y), \quad \text{para} \quad -\infty < y < \infty$$

## Distribuição do máximo e o mínimo em uma amostra aleatória

para o caso  $Y_1$ , para  $(-\infty < y < \infty)$

$$\begin{aligned} G_1(y) &= P(Y_1 \leq y) = 1 - P(Y_1 > y) \\ &= 1 - P(X_1 > y, \dots, X_n > y) \\ &= 1 - P(X_1 > y) \dots P(X_n > y) \\ &= 1 - [1 - F(y)] \dots [1 - F(y)] \\ &= 1 - [1 - F(y)]^n \end{aligned}$$

a f.d.p de  $Y_1$  pode ser determinado derivando:

$$g_1(y) = n [1 - F(y)]^{n-1} f(y), \quad \text{para } -\infty < y < \infty$$



## Valor esperado

Sejam  $X$  e  $Y$  duas v.a. conjuntamente distribuídos com f.m.p conjunta  $p(x, y)$  ou f.d.p. conjunta  $f(x, y)$  dependendo em que as variáveis são discretas ou contínuas. Então, o valor esperade de uma função  $h(X, Y)$  denotado por  $E[h(X, Y)]$  ou  $\mu_{h(X, Y)}$  é

$$E[h(X, Y)] = \begin{cases} \sum_x \sum_y h(x, y) \cdot p(x, y) & \text{no caso discreto} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y) \cdot f(x, y) dx dy & \text{no caso contínuo} \end{cases}$$

## exemplo

Considere a distribuição conjunta de  $X$  e  $Y$ :

Y	X				$p(y)$
	0	1	2	3	
0	1/8	2/8	1/8	0	1/2
1	0	1/8	2/8	1/8	1/2
$p(x)$	1/8	3/8	3/8	1/8	1

Encontre a distribuição de

- 1 a soma  $X + Y$ , o valor esperado  $E(X + Y)$
- 2 o produto  $XY$

## Exemplo

Solução  
a distribuição da soma é:

$x + y$	0	1	2	3	4
$p(x + y)$	1/8	2/8	2/8	2/8	1/8

O valor esperado

$$E(x + y) = 0 \times 1/8 + 1 \times 2/8 + \dots + 4 \times 1/8 = 2$$

## Exemplo

Solução  
a distribuição do produto é:

$xy$	0	1	2	3
$p(xy)$	4/8	1/8	2/8	1/8

## definição

A covariância entre duas v.a.'s  $X$  e  $Y$  é

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] =$$

$$\begin{cases} \sum_x \sum_y (x - \mu_X)(y - \mu_Y) p(x, y) & \text{caso discreto} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_X)(y - \mu_Y) f(x, y) dx dy & \text{caso contínuo} \end{cases}$$

## Forma curta para o cálculo da covariância

$$\text{Cov}(X, Y) = E(X, Y) - \mu_X \cdot \mu_Y$$

## definição

O coeficiente de correlação de  $X$  e  $Y$ , denotado por  $Corr(X, Y)$ ,  $\rho_{X,Y}$ , ou apenas  $\rho$ , é definida por :

$$\rho_{X,Y} = \frac{Cov(X, Y)}{\sigma_X \cdot \sigma_Y}$$

## Proposições para a Correlação

- 1. Se  $a$  e  $c$  são ambos positivos ou ambos negativos,

$$\text{Corr}(aX + b, cY + d) = \text{Corr}(X, Y)$$

- 2. Para duas v.a.'s  $X$  e  $Y$  quaisquer:

$$-1 \leq \text{Corr}(X, Y) \leq 1$$



## Proposições para a Correlação

- 3. Se  $X$  e  $Y$  são independentes, então

$$\rho = 0$$

mas,  $\rho = 0$  não implica independência.

- 4.  $\rho = 1$  ou  $\rho = -1$  se e somente se

$$Y = aX + b$$

para alguns números  $a$  e  $b$  com  $a \neq 0$

## Definição

Uma estatística é qualquer quantidade cujo valor pode ser calculado dos dados amostrais (função de valores amostrais).

Antes de obter os dados (amostra), existe incerteza sobre qual será o valor de uma particular estatística

Uma estatística é uma v.a. denotada por uma letra maiúscula; uma letra minúscula representará o valor observado da estatística.

## Estatísticas comuns

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

: média amostral

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

: variância amostral

$$X_{(1)} = \min\{X_1, \dots, X_n\}$$

: mínimo da amostra

$$X_{(n)} = \max\{X_1, \dots, X_n\}$$

: maximo da amostra

## Definição de amostra aleatória

As v.a.  $X_1, \dots, X_n$  formam uma **amostra aleatória simples** de tamanho  $n$ , se:

- 1. Os  $X_i$ 's são v.a. independentes.
- 2. Cada  $X_i$  tem a mesma distribuição de probabilidade.

## Experimentos simulados

As seguintes características devem ser especificadas:

- 1. A estatística de interesse
- 2. A distribuição da população
- 3. O tamanho da amostra  $n$
- 4. O número de repetições  $k$

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
Estatísticas e suas distribuições

Estatísticas

**Amostras aleatórias**

A distribuição da média amostral

O T.L.C.

Distribuição Lognormal aproximada

Distribuição de uma combinação linear

Valor esperado de uma combinação linear

Variância de uma combinação linear

Diferença entre duas v.a.

Diferença entre v.a. normais

## Distribuições amostrais

O propósito da inferência estatística é fazer afirmações sobre parâmetros populacionais, através de dados amostrais.

Usamos uma a.a.s. de  $n$  elementos da população, e a decisão será baseada na estatística  $T$ , que será função da amostra  $(X_1, \dots, X_n)$ , i.e.,

$$T = f(X_1, \dots, X_n)$$

## Distribuições amostrais

O propósito da inferência estatística é fazer afirmações sobre parâmetros populacionais, através de dados amostrais.

Usamos uma a.a.s. de  $n$  elementos da população, e a decisão será baseada na estatística  $T$ , que será função da amostra  $(X_1, \dots, X_n)$ , i.e.,

$$T = f(X_1, \dots, X_n)$$

Colhida a amostra, teremos observado um valor particular de  $T$  ( $t_0$ ).  
Baseados naquele valor é que faremos uma afirmação sobre  $\theta$ .

## Distribuições amostrais

O propósito da inferência estatística é fazer afirmações sobre parâmetros populacionais, através de dados amostrais.

Usamos uma a.a.s. de  $n$  elementos da população, e a decisão será baseada na estatística  $T$ , que será função da amostra  $(X_1, \dots, X_n)$ , i.e.,

$$T = f(X_1, \dots, X_n)$$

Colhida a amostra, teremos observado um valor particular de  $T$  ( $t_0$ ). Baseados naquele valor é que faremos uma afirmação sobre  $\theta$ .



## Distribuições amostrais

A distribuição amostral da estatística  $T$  é obtida quando retiram-se todas as amostras da população segundo o plano amostral adotado.

Esquemáticamente temos:

- 1 uma população  $X$  com parâmetro de interesse  $\theta$

## Distribuições amostrais

A distribuição amostral da estatística  $T$  é obtida quando retiram-se todas as amostras da população segundo o plano amostral adotado.

Esquemáticamente temos:

- 1 uma população  $X$  com parâmetro de interesse  $\theta$
- 2 todas as amostras retiradas da população (de acordo com o plano amostral)

## Distribuições amostrais

A distribuição amostral da estatística  $T$  é obtida quando retiram-se todas as amostras da população segundo o plano amostral adotado.

Esquemáticamente temos:

- 1 uma população  $X$  com parâmetro de interesse  $\theta$
- 2 todas as amostras retiradas da população (de acordo com o plano amostral)
- 3 para cada amostra, calcula-se o valor  $t$  da estatística  $T$

## Distribuições amostrais

A distribuição amostral da estatística  $T$  é obtida quando retiram-se todas as amostras da população segundo o plano amostral adotado.

Esquemáticamente temos:

- 1 uma população  $X$  com parâmetro de interesse  $\theta$
- 2 todas as amostras retiradas da população (de acordo com o plano amostral)
- 3 para cada amostra, calcula-se o valor  $t$  da estatística  $T$
- 4 os valores de  $t$  formam uma nova população, cuja distribuição é a distribuição amostral de  $T$ .

## Distribuições amostrais

A distribuição amostral da estatística  $T$  é obtida quando retiram-se todas as amostras da população segundo o plano amostral adotado.

Esquemáticamente temos:

- 1 uma população  $X$  com parâmetro de interesse  $\theta$
- 2 todas as amostras retiradas da população (de acordo com o plano amostral)
- 3 para cada amostra, calcula-se o valor  $t$  da estatística  $T$
- 4 os valores de  $t$  formam uma nova população, cuja distribuição é a distribuição amostral de  $T$ .

## Exemplo

Considere a população  $\{1, 3, 5, 5, 7\}$

- 1 Construa a distribuição conjunta bidimensional  $(X_1, X_2)$
- 2 calcule a distribuição da estatística  $\bar{X} = \frac{X_1 + X_2}{2}$ .
- 3 calcule a distribuição da estatística  $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$

## Solução

a distribuição do par  $(X_1, X_2)$  é:

$X_2$	$X_1$				total
	1	3	5	7	
1	1/25	1/25	2/25	1/25	1/5
3	1/25	1/25	2/25	1/25	1/5
5	2/25	2/25	4/25	2/25	2/5
7	1/25	1/25	2/25	1/25	1/5
Total	1/5	1/5	2/5	1/5	1

## Solução

Para cada par  $(X_1, X_2)$ , calculamos a estatística  $\bar{X}$  e a distribuição será:

$\bar{X}$	1	2	3	4	5	6	7	total
$p(\bar{X})$	1/25	2/25	5/25	6/25	6/25	4/25	1/25	1



## Solução

Para cada par  $(X_1, X_2)$ , calculamos a estatística  $S^2$  e a distribuição será:

$s^2$	0	2	8	18	total
$p(S^2 = s^2)$	7/25	10/25	6/25	2/25	1

## Usando a média amostral

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição com média  $\mu$  e desvio padrão  $\sigma$ . Então:

- 1  $E(\bar{X}) = \mu_{\bar{X}} = \mu$
- 2  $V(\bar{X}) = \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$

Em adição: Com  $T_0 = X_1 + \dots + X_n$ ,

$$E(T_0) = n\mu$$

$$V(T_0) = n\sigma^2, \quad \text{e}$$

$$\sigma_{T_0} = \sqrt{n}\sigma$$

## Provas

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} (E(X_1) + \dots + E(X_n)) \\ &= \frac{1}{n} (\mu + \dots + \mu) = \mu \end{aligned}$$

$$\begin{aligned} Var(\bar{X}) &= Var\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n^2} (Var(X_1) + \dots + Var(X_n)) \\ &= \frac{1}{n^2} (\sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{n} \end{aligned}$$

## Provas

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} (E(X_1) + \dots + E(X_n)) \\ &= \frac{1}{n} (\mu + \dots + \mu) = \mu \end{aligned}$$

$$\begin{aligned} Var(\bar{X}) &= Var\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n^2} (Var(X_1) + \dots + Var(X_n)) \\ &= \frac{1}{n^2} (\sigma^2 + \dots + \sigma^2) = \frac{\sigma^2}{n} \end{aligned}$$

## O teorema central do limite.

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição com média  $\mu$  e variância  $\sigma^2$ . Então, se  $n$  é suficientemente grande,  $\bar{X}$  terá aproximadamente uma distribuição normal com  $\mu_{\bar{X}} = \mu$  e  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , e  $T_0$  também tem uma distribuição aproximadamente normal, com parâmetros

$$\mu_{T_0} = n\mu,$$

$$\sigma_{T_0} = n\sigma^2$$

Quanto maior for o valor de  $n$ , melhor a aproximação.

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
Estatísticas e suas distribuições

Estatísticas  
Amostras aleatórias  
A distribuição da média amostral  
**O T.L.C.**  
Distribuição Lognormal aproximada  
Distribuição de uma combinação linear  
Valor esperado de uma combinação linear  
Variância de uma combinação linear  
Diferença entre duas v.a.  
Diferença entre v.a. normais

## Simulação do T.L.C




Figura: O Teorema do Limite Central

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
Estatísticas e suas distribuições

Estatísticas  
Amostras aleatórias  
A distribuição da média amostral  
O T.L.C.  
Distribuição Lognormal aproximada  
Distribuição de uma combinação linear  
Valor esperado de uma combinação linear  
Variância de uma combinação linear  
Diferença entre duas v.a.  
Diferença entre v.a. normais

## Regra de Ouro

Se  $n > 30$ , o T.L.C. pode ser utilizado.

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
**Estatísticas e suas distribuições**

Estatísticas  
Amostras aleatórias  
A distribuição da média amostral  
**O T.L.C.**  
Distribuição Lognormal aproximada  
Distribuição de uma combinação linear  
Valor esperado de uma combinação linear  
Variância de uma combinação linear  
Diferença entre duas v.a.  
Diferença entre v.a. normais

## Exemplo

Uma máquina enche pacotes de café, com distribuição normal com média 500 e variancia 100. Colhe-se uma amostra de  $n = 100$  pacotes, os que são pesados. Qual a probabilidade de encontrarmos a média dos 100 pacotes diferindo de 500 em menos de dois gramas.



## Solução

Tomamos  $X \sim N(500, 100)$ , pelo T.L.C, teremos que  
 $X \sim N(500, 100/100 = 1)$ . Portanto,

$$P(|\bar{X} - 500| < 2) = P(498 < \bar{X} < 502) = P(-2 < Z < 2) \approx 95\%$$

Distribuições de probabilidade conjunta e Amostras Aleatórias  
Variáveis aleatórias independentes  
Valores esperados, Covariâncias e Correlação  
Estatísticas e suas distribuições

Estatísticas  
Amostras aleatórias  
A distribuição da média amostral  
O T.L.C.  
Distribuição Lognormal aproximada  
Distribuição de uma combinação linear  
Valor esperado de uma combinação linear  
Variância de uma combinação linear  
Diferença entre duas v.a.  
Diferença entre v.a. normais

## corolários

Corolário 1: Se  $(X_1, \dots, X_n)$  é uma a.a.s. da população  $X$  com média  $\mu$  e variância  $\sigma^2$  finita, então:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Corolário 2: se  $e = \bar{X} - \mu$  então

$$e \sim N(0, \sigma^2/n)$$

## corolários

Corolário 1: Se  $(X_1, \dots, X_n)$  é uma a.a.s. da população  $X$  com média  $\mu$  e variância  $\sigma^2$  finita, então:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Corolário 2: se  $e = \bar{X} - \mu$  então

$$e \sim N(0, \sigma^2/n)$$

## Distribuição amostral da proporção

Considere uma população em que a proporção de elementos portadores de certa característica é  $p$ . A v.a  $X$  é definida da seguinte maneira:

$$X = \begin{cases} 1, & \text{se o indivíduo for portador da característica} \\ 0, & \text{se o indivíduo não for portador da característica} \end{cases}$$

Temos que  $\mu = E(X) = p$ ,  $\sigma^2 = \text{Var}(X) = p(1 - p)$

## Distribuição amostral da proporção

Se retirarmos uma a.a.s. e indicando  $Y_n$  o total de indivíduos na amostra, portadores da característica, teremos que:

$$Y_n \sim \text{bin}(n, p)$$

Seja  $\hat{p}$  a proporção de indivíduos na amostra, portadores da característica:

$$\hat{p} = \frac{Y_n}{n}$$

$$\text{Então } P(Y_n = k) = P\left(\frac{Y_n}{n} = \frac{k}{n}\right) = P\left(\hat{p} = \frac{k}{n}\right)$$

## Distribuição amostral da proporção (aproximação)

Seja a v.a  $Y_n = X_1 + X_2 + \dots + X_n$  onde cada  $X_i$  tem distribuição Bernoulli com média  $\mu = p$  e variância  $\sigma^2 = p(1 - p)$  e são independentes entre si. Podemos escrever:

$$Y_n = n\bar{X}$$

pelo T.L.C,  $\bar{X}$  tem distribuição normal com média  $p$  e variância  $\frac{p(1-p)}{n}$ , ou seja:

$$\bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

## Distribuição amostral da proporção

Logo

$$Y_n = n\bar{X} \sim N(np, np(1-p))$$

observe que  $\bar{X}$  é a própria  $\hat{p}$  e, para  $n$  grande,

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

## Determinação do tamanho da amostra

Suponha que desejamos estimar a média  $\mu$  e para tanto usamos a média amostral  $\bar{X}$ , baseada numa amostra de tamanho  $n$ .

Suponha que desejamos determinar o valor de  $n$  tal que:

$$P(|\bar{X} - \mu| \leq \epsilon) \geq \gamma$$

com  $0 < \gamma < 1$  e  $\epsilon$  é o erro amostral máximo permissível (ambos dados).



## Determinação do tamanho da amostra

Como  $\bar{X} \sim N(\mu, \sigma^2/n)$ , logo  $\bar{X} - \mu \sim N(0, \sigma^2/n)$  e pode ser escrita como:

$$P(-\epsilon \leq \bar{X} - \mu \leq \epsilon) = P\left(\frac{-\sqrt{n}\epsilon}{\sigma} \leq Z \leq \frac{\sqrt{n}\epsilon}{\sigma}\right) \approx \gamma$$

Com  $Z = (\bar{X} - \mu)\sqrt{n}/\sigma$ . Dado  $\gamma$ , obtemos  $z_\gamma$  da  $N(0, 1)$ , tal que  $P(-z_\gamma < Z < z_\gamma) = \gamma$  de modo que

$$\frac{\sqrt{n}\epsilon}{\sigma} = z_\gamma$$

do que se obtêm finalmente  $n = \frac{\sigma^2 z_\gamma^2}{\epsilon^2}$

## Definição

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição para a qual apenas são possíveis os valores positivos [ $P(X_i > 0) = 1$ ].  
Então, para  $n$  suficientemente grande, o produto  $Y = X_1 \cdot X_2 \dots X_n$  tem aproximadamente uma distribuição log-normal

## C.L.

Dada uma coleção de  $n$  v.a.  $X_1, \dots, X_n$  e  $n$  constantes numéricas  $a_1, \dots, a_n$ , a v.a.

$$Y = a_1 X_1 + \dots + a_n X_n = \sum_{i=1}^n a_i X_i$$

Isto é chamado de combinação linear dos  $X_i$ 's

## Esperança de uma C.L.

Seja  $X_1, \dots, X_n$  com médias  $\mu_1, \mu_2, \dots, \mu_n$  e variâncias de  $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ , respectivamente.

Ainda que os  $X_i$ 's não sejam independentes,

$$\begin{aligned} E(a_1 X_1 + \dots + a_n X_n) &= a_1 E(X_1) + \dots + a_n E(X_n) \\ &= a_1 \mu_1 + \dots + a_n \mu_n \end{aligned}$$

## Variância de uma C.L.

Se  $X_1, \dots, X_n$  são independentes,

$$\begin{aligned} V(a_1 X_1 + \dots + a_n X_n) &= a_1^2 V(X_1) + \dots + a_n^2 V(X_n) \\ &= a_1^2 \sigma_1^2 + \dots + a_n^2 \sigma_n^2 \end{aligned}$$

e

$$\sigma_{a_1 X_1 + \dots + a_n X_n} = \sqrt{a_1^2 \sigma_1^2 + \dots + a_n^2 \sigma_n^2}$$

## Variância de uma C.L.

Para qualquer  $X_1, \dots, X_n$ ,

$$V(a_1 X_1 + \dots + a_n X_n) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(X_i, X_j)$$

## definição

$$E(X_1 - X_2) = E(X_1) - E(X_2)$$

e se  $X_1$  e  $X_2$  são independentes,

$$V(X_1 - X_2) = V(X_1) + V(X_2)$$

## Diferença

Se  $X_1, \dots, X_n$  são v.a. independentes e normalmente distribuídas, então qualquer combinação linear dos  $X_i$ 's também têm uma distribuição normal.

A diferença  $X_1 - X_2$  entre duas v.a. independentes e normalmente distribuídas, é também normalmente distribuída.